



MBA em Engenharia de Dados

Data Integration e Pipelines


Aula 1 — Fundamentos, ETL/ELT, Databricks e Pipeline de Fraude

Prof. Rafael S Novo Pereira

Sobre a disciplina - Data Integration e Pipelines

Você sai daqui sabendo construir e orquestrar pipelines de integração de dados — do conceito à prática.

Os 4 temas da disciplina (segundo a ementa) — e onde a aula de hoje se encaixa:



Ferramentas que vamos conhecer: Airflow · dbt · Talend · Apache NiFi · Dagster · Databricks.

Rafael S Novo Pereira– Short Bio



Pai da Lorenzo, e casado com a Juliana.

Formação Acadêmica: Mestre em Ciência da Computação, formado em Sistemas de Informação e Matemática, com pós graduação em Gestão de Projetos e Engenharia de Software e Dados.

15 anos de Experiência com Tecnologia/Dados/IA:

makro

sodexo



Bayer

PEERS Consulting + Technology



Atualmente IT Manager Peers.

IT Squad Líder na Sodexo.

System Development Coordinator Makro.

Além de mais de 10 como Professor de Software Architect/Data em MBAs e Graduações em diversas Instituições.



FIA.P

Senac


CPS
Centro
Paula Souza

<https://www.linkedin.com/in/rafsp/>



Quem é você? — apresentação rápida

Antes de começar, queremos te conhecer. Em 30 segundos, conte para a turma:



Seu nome e sua área

De onde você fala — empresa, time, o que faz no dia a dia.

Sua experiência com dados

De "nunca programei" até "já rodo Spark em produção" — todos os níveis são bem-vindos.

O que espera levar

Existe algum problema que já tem onde trabalha que acredita que a disciplina possa te ajudar?

Plataformas que já utilizou ou usa

Resposta de um bom Consultor




O que vamos aprender hoje

A aula tem 4 momentos — do conceito ao código rodando na sua tela.

1

Fundamentos

O problema da integração, pipelines, batch vs streaming, ETL vs ELT e suas ferramentas.



2

Onde os dados moram

Lakehouse, arquitetura Medallion (Bronze/Silver/Gold) e o Unity Catalog.



3

A plataforma Databricks

O que é, por que importa, a verdade sobre streaming e a configuração do zero.



databricks

4

Lab — mão na massa

Construir um pipeline de detecção de fraude de ponta a ponta, no Databricks.



O problema que ninguém vê — até a diretoria ver

Segunda-feira, 8h47. A diretoria abre o dashboard do faturamento de maio.

ERP financeiro

R\$ 4,2 mi



Sistema de vendas

R\$ 4,7 mi



Planilha da diretoria

R\$ 3,9 mi




Três sistemas. Três respostas.

Para a mesma pergunta. Qual é a verdade?



Por que isso acontece

Os dados nascem espalhados em sistemas que não foram feitos para conversar.



Cada fonte tem seu formato, sua regra de negócio e seu horário de atualização.


O que é Data Integration

Combinar dados de fontes diferentes numa visão única, consistente e confiável.



Heterogeneidade

Formatos e semânticas diferentes: ERP, API, CSV, app.



Temporalidade

Cada fonte atualiza num ritmo: tempo real, diário, semanal.



Confiabilidade


Duplicados, nulos, divergências. Qualidade é pré-requisito.

Na prática: garantir que, quando alguém abre um dashboard, os números estão certos.



O que é um pipeline de dados

Como uma linha de montagem: a matéria-prima entra de um lado e o produto sai do outro.



Cada estação faz uma coisa só, na ordem certa, de forma repetível e automatizável.

Pergunta para a turma: qual etapa você acha que mais dá trabalho num projeto real?

Dois ritmos: batch vs streaming

Dois jeitos de mover dados — e uma analogia que todo mundo conhece.

Batch — o correio



- Junta os dados e entrega de uma vez, em janelas de tempo.
- Latência de minutos a horas.
- Quando usar: relatórios, fechamentos.
- Ex.: faturamento consolidado todo dia às 6h.

Streaming — o WhatsApp




- Processa cada evento na hora em que acontece.
- Latência de segundos a milissegundos.
- Quando usar: tempo real, alertas.
- Ex.: alerta de fraude no segundo da transação.

Esta disciplina foca em batch; streaming de verdade (evento a evento) é tema de Stream Processing.

ETL vs ELT — onde a transformação acontece

ETL = cozinha terceirizada (vem pronto). ELT = cozinha própria (cozinha sob demanda).



A única diferença que importa: ONDE a transformação acontece — fora ou dentro do destino.

As ferramentas de ETL/ELT

FIAP

Você não decora ferramenta — entende o papel de cada uma. As três da ementa:



Orquestra: define a ordem e o horário das etapas (o maestro, via DAGs).



Transforma com SQL versionado, testes e documentação (o T do ELT).



Plataforma ETL clássica, visual, com centenas de conectores prontos.

Hoje a prática é no Databricks (que também orquestra, via Workflows). As demais aparecem nas próximas aulas.

Você já entende o terreno

Recapitulando as três analogias antes de ir para a plataforma:

Pipeline

linha de montagem

cada estação faz uma coisa, na ordem certa



Batch vs streaming

correio vs WhatsApp


em lote ou evento a evento



ETL vs ELT

cozinhas diferentes

onde a transformação acontece



Próximo: onde esses dados de fato moram — Lakehouse, Medallion e o Unity Catalog.

Onde os dados moram: o Lakehouse

Antes vinham dois mundos separados. O Lakehouse junta os dois.

Data Warehouse




- Dados organizados, prontos para análise.
- Rápido e governado.
- Caro e rígido.

Data Lake



- Guarda tudo cru, qualquer formato.
- Barato e flexível.
- Vira um "pântano" sem governança.

Lakehouse




- O melhor dos dois.
- Storage barato do lake + performance e governança do warehouse.
- É o que o Databricks faz (Delta Lake).

Analogia: o lake é o depósito; o warehouse é a vitrine. O lakehouse é a loja com os dois no mesmo prédio.



Arquitetura Medallion: Bronze, Silver, Gold

O padrão para organizar um pipeline em camadas de qualidade crescente.



Exatamente como chegaram. Sem transformação. O cofre dos dados originais.

Tipos corrigidos, nulos tratados, duplicatas removidas, regras aplicadas.

Métricas agregadas, KPIs, pronto para dashboards. É o que a diretoria vê.



Anatomia da plataforma: o Unity Catalog

Unity Catalog



Antes do lab: pense num prédio de arquivos — é assim que o Databricks organiza tudo.

1

CATÁLOGO • workspace

O nível mais alto — o "prédio". Agrupa todos os schemas. Na Free Edition, o padrão é workspace.

2

SCHEMA • default

O "andar" dentro do catálogo. Agrupa as tabelas e os volumes. O padrão é default.

3

OBJETOS • Tabela vs. Volume

Tabela: dados em linhas/colunas, lidos por SQL. Volume: arquivos crus (o CSV), lidos pelo caminho /Volumes/...

Endereço completo: `catalogo.schema.tabela = workspace.default.bronze_transacoes`. O CSV cru vai num Volume; as camadas viram Tabelas.

Bloco 3 — A plataforma

Databricks

O que é, por que importa, e como configurar do zero — passo a passo.



databricks

Mas antes: o que é Apache Spark?



Motor de processamento de dados distribuído e open-source. Em vez de processar dados num único computador, o Spark divide o trabalho entre dezenas ou centenas de máquinas simultaneamente. É como ter 100 estagiários organizando planilhas ao mesmo tempo em vez de um sozinho.



Rápido

Processa dados em memória (RAM), até 100x mais rápido que MapReduce (Hadoop)



Multi-linguagem

Python, SQL, Scala, R e Java.
Você vão usar Python e SQL nos labs.



Unificado

Batch, streaming, ML e grafos
— tudo no mesmo motor.
Não precisa de 5 ferramentas



Escala na cloud


Roda em AWS, Azure e GCP.
Adiciona máquinas conforme a demanda cresce.

O que é o Databricks — e por que importa

Plataforma unificada de dados e IA, criada em 2013 pelos criadores do Apache Spark (UC Berkeley).

Por que um engenheiro de dados se importa

- Reúne engenharia, analytics, ML e IA no mesmo ambiente.
- É o Spark sem dor de cabeça: escala sem você gerenciar servidores.
- Construído sobre Spark + Delta Lake + Unity Catalog.
- Lakehouse: o barato do lake com a performance do warehouse.



US\$ 175 bilhões de valuation (Série L, mar/2026) · usado por Nubank, iFood, Itaú, Shell e milhares de empresas.



Databricks faz streaming? A resposta honesta

Sim e não — depende do modo. A diferença importa numa prova de MBA.



Micro-batch (padrão)

- Processa em pequenos lotes, a cada intervalo curto.
- Latência de segundos — baixíssima, mas NÃO é evento a evento.
- Barato e ideal para ETL e Medallion.
- É o que vamos usar nesta disciplina.

Real-Time Mode (GA em mar/2026)

- Processa cada evento continuamente, conforme chega.
- Latência de milissegundos (p99 < 300ms, até ~5ms).
- Streaming de verdade — compete com o Apache Flink.
- Exige compute dedicado; para casos críticos.

Analogia: micro-batch = ônibus a cada poucos segundos (lotes pequenos). Real-Time Mode = moto-táxi: cada passageiro no instante em que chega.

Resumo: por padrão é quase-tempo-real (micro-batch). Streaming evento-a-evento é tema de Stream Processing.



A família Genie: a IA dentro da plataforma

Dois assistentes de IA — um para quem é de negócio, outro para quem é de engenharia.



Genie · para o negócio

- Você pergunta em português; ele devolve SQL, gráfico e explicação.
- Sobre dados governados pelo Unity Catalog.
- Ex.: "qual a taxa de fraude por canal?"
- Para analistas, gestores e diretoria.

Genie Code · para a engenharia

- Assistente que gera, corrige e explica código no notebook.
- Conhece seus schemas e o lineage.
- Era o Databricks Assistant (renomeado em 2026).
- Para o engenheiro de dados.

A moral: a Genie só responde bem se os dados estiverem organizados. Lixo entra, lixo sai — ela depende da Silver e da Gold.

Databricks Free Edition — o nosso ambiente

O que é

- Versão gratuita e permanente (lançada em jun/2025).
- Serverless: o compute liga e desliga sozinho — sem gerenciar cluster.
- Unity Catalog habilitado por padrão (catálogo, schemas, volumes).
- Inclui 1 SQL Warehouse para rodar SQL.
- Login com o e-mail FIAP (conta Microsoft).

Atenção em sala

NÃO clique nos botões de cloud (AWS, Azure, GCP) — eles criam um trial PAGO de 14 dias. Queremos a Free Edition.

Passo a passo — configurar o ambiente

1

Acessar a Free Edition

Entre em databricks.com/try-databricks e clique em "Get Free Edition".

2

Entrar com a FIAP

Clique em "Sign in with Microsoft" e use seu e-mail @fiap.com.br.

3

Criar o Volume

Catalog → workspace → default → Create → Volume. Nome: aulamba.

4

Subir o dataset

Abra o Volume aulamba e faça upload do `card_transdata.csv` (≈1 milhão de linhas).

Passo a passo — garantir a extração dos dados

Num notebook, leia o CSV de dentro do Volume e valide. É aqui que a extração se confirma.

```
# 1) Ler o arquivo de dentro do Volume
df = spark.read.csv(
    "/Volumes/workspace/default/aulamba/card_transdata.csv",
    header=True, inferSchema=True)

# 2) Validar a extração
print(f"Registros: {df.count():,}")
print(f"Colunas: {len(df.columns)}")
df.printSchema()
display(df.limit(10))
```

O que você deve ver

≈ 1.000.000 registros e 8 colunas. Se bateu, a extração funcionou.

Se der erro "Path not found"

Confirme que o Volume aulamba existe e que o CSV está dentro dele.

Por que ler do Volume e não criar tabela? Para enxergar o dado CRU entrando — é o conceito de Bronze.

Lab — o que vamos construir

Um pipeline de detecção de fraude de ponta a ponta, no Databricks.

O dataset

- card_transdata: ≈ 1 milhão de transações de cartão.
- 8 colunas: distância de casa, valor, uso de chip, online...
- Campo-alvo: fraud (0 = legítima, 1 = fraude).
- Dataset real do Kaggle — nada de exemplo de brinquedo.

O que você vai fazer

- Ingerir o CSV cru (Bronze).
- Limpar e criar regras de risco (Silver).
- Calcular métricas e marcar suspeitas (Gold).
- Versionar (time travel) e validar a qualidade.

Arquitetura: Bronze → Silver → Gold com Delta Lake. Do CSV cru às métricas de fraude — automatizável.

Lab — o pipeline Bronze, Silver, Gold



Cada camada é uma tabela Delta. Você pode consultar, versionar e reprocessar qualquer uma delas.

Lab — além do pipeline: governança e IA



Time travel

O Delta versiona cada escrita. Dá para voltar a uma versão anterior — o "Ctrl+Z" dos dados.



Quality gate

Antes de publicar a Gold, validamos a taxa de fraude. Fora da faixa esperada? O pipeline para.



Genie na Gold

Pergunte em português sobre a tabela que VOCÊ criou — e veja a IA responder com SQL e gráfico.

O que aprendemos hoje

Em um dia, você saiu do problema de negócio a um pipeline rodando.



Por que Data Integration existe — e os 3 desafios (heterogeneidade, tempo, confiança).



Pipeline, batch vs streaming e ETL vs ELT — com analogias que ficam.



Onde os dados moram: Lakehouse, Medallion e o Unity Catalog (Tabela vs Volume).



Databricks: o que é, a verdade sobre streaming, a configuração e a extração.



Um pipeline de fraude Bronze → Silver → Gold, construído por você.

Próxima aula — e um desafio para fixar

Próxima aula (tema da ementa): Data Wrangling e Qualidade de Dados em Pipelines.

Quiz relâmpago — responda mentalmente (vale discutir):

- 1 Qual a diferença entre ETL e ELT — e onde a transformação acontece em cada um?
- 2 Por que o CSV cru vai num Volume, e a Bronze/Silver/Gold viram Tabelas?
- 3 Databricks faz streaming de verdade? Em que modo, e desde quando?



Obrigado!

Prof. Rafael S Novo Pereira

Prof.rafaelpereira@fiap.com.br / [linkedin.com/in/rafsp](https://www.linkedin.com/in/rafsp)