

Data Integration e Pipelines

Lab 00 — Criação do Ambiente no Databricks Free Edition

Neste roteiro você vai acessar o Databricks Free Edition usando seu e-mail FIAP, conhecer a plataforma e preparar o ambiente para os laboratórios da disciplina. Ao final, terá o workspace funcionando e o dataset pronto para uso.

Este tutorial contém quatro partes:

Parte 1 — Acesso ao Databricks Free Edition (login com e-mail FIAP)

Parte 2 — Tour pela plataforma: entendendo cada seção

Parte 3 — Criando seu primeiro notebook e testando o ambiente

Parte 4 — Upload do dataset card_transdata.csv

Dica: Tempo estimado: 15 a 20 minutos. Você precisará do seu e-mail institucional FIAP (@fiap.com.br).

Sobre a Free Edition: Lançada em junho de 2025, a Databricks Free Edition é uma versão permanente e gratuita da plataforma. Diferente da Community Edition (que vocês podem ter visto em outros cursos), a Free Edition roda com compute serverless — ou seja, não precisa criar ou gerenciar clusters manualmente. O ambiente já vem pronto para uso.


Parte 1 — Acesso ao Databricks Free Edition

O acesso ao Databricks é feito pelo e-mail institucional da FIAP. Não é necessário criar uma conta nova — basta acessar com seu login Microsoft.

Passo a passo


Passo 1: Acesse o site de login do Databricks:

<https://databricks.com/try-databricks>



Passo 2: Clique na opção "Sign in with Microsoft" (ou "Entrar com Microsoft"). Como o seu e-mail FIAP (@fiap.com.br) é uma conta Microsoft, o login será feito automaticamente pelo sistema de autenticação da FIAP.

Dica: Se aparecer uma tela pedindo First Name, Last Name, Company e Title, preencha normalmente. Em Company coloque "FIAP" e em Title coloque "Estudante MBA". Depois selecione "Get Started with Free Edition".



FOR PERSONAL USE

Free Edition

Try Databricks Free Edition to build data and AI skills at your own pace — no cloud account required.

Get Free Edition

databricks
Free Edition

Inscreva-se na edição gratuita

Explore e aprenda as ferramentas mais recentes de dados e IA.

Continuar com o Google

Continuar com a Microsoft

ou

Ao continuar, você concorda com nossos [Termos de Serviço](#), [Aviso de Privacidade](#) e termos de compartilhamento de e-mail corporativo. ©

Continuar com e-mail

databricks

Com que finalidade você usará o Databricks?

Comece gratuitamente. Não é necessário cartão de crédito.

Para trabalho

- ✓ Grátis por 14 dias com até US\$ 400 em créditos*
- ✓ Trabalhe com qualquer dado em qualquer nuvem
- ✓ Plataforma completa com Termos e SLAs corporativos

Comece a avaliação com a configuração expressa

ou configure com sua nuvem

*Aplicam-se os termos para créditos

Para uso pessoal

- ✓ Grátis para sempre
- ✓ Aprenda e crie com conjuntos de dados exploratórios
- ✓ Principais recursos com limites de uso pessoal, Termos e SLAs

Obter a edição gratuita

Inscrevendo-se como rafael.pereira01@cps.sp.gov.br

Passo 3: Após o login, você será redirecionado para a tela do Workspace. É aqui que todo o trabalho acontece.

Atenção: NÃO clique nos botões de provedores de cloud (AWS, Azure, GCP) que podem aparecer em destaque. Esses botões criam uma conta Trial de 14 dias com cobrança. Queremos a Free Edition, que é gratuita e permanente.

Passo 4: Pronto! Seu workspace está ativo. Na próxima vez que precisar acessar, vá diretamente para:

<https://accounts.cloud.databricks.com>

Ou acesse o workspace diretamente pela URL que aparece no navegador após o login.




databricks
Free Edition

Estamos configurando sua conta

Vamos redirecionar para seu workspace em alguns segundos.

↻

Iniciar o workspace



O que é diferente da Community Edition?

Se vocês já usaram o Databricks Community Edition em outra disciplina, vão notar diferenças. A Free Edition é mais recente (2025) e funciona de forma diferente:

Aspecto	Community Edition	Free Edition (nossa)
Compute	Cluster manual (criar, esperar, reiniciar)	Serverless (pronto para usar, sem gerenciar)
Desliga sozinho?	Sim, após 1-2h de inatividade	Serverless desliga/liga automaticamente
SQL Warehouse	Não disponível	1 SQL Warehouse 2X-Small incluído
Unity Catalog	Não disponível	Habilitado por padrão
Login	E-mail + senha própria	Microsoft (FIAP) ou Google
Expira?	Não	Não (pode ser excluída após inatividade prolongada)


Parte 2 — Tour pela Plataforma

Agora que você está logado, vamos entender o que cada seção do menu lateral faz. Essa orientação inicial vai economizar tempo nos próximos labs.

Menu lateral esquerdo

No topo do menu lateral esquerdo, você verá o botão "+ New" (em azul). Esse é o atalho principal para criar recursos.


Menu	O que faz
+ New	Cria notebooks, arquivos, queries, dashboards, pastas e pipelines ETL. É o botão que vocês mais vão usar.
Home	Tela inicial com atalhos rápidos e tutoriais sugeridos.
Workspace	Seus notebooks e arquivos organizados em pastas. É onde seu trabalho fica salvo.
Recents	Atalho para notebooks e arquivos abertos recentemente.
Catalog	Unity Catalog — gerencia tabelas, schemas, volumes de dados. É onde os datasets ficam registrados.
Jobs & Pipelines	Agendar e orquestrar notebooks como jobs automáticos (equivalente simplificado do Airflow).
Compute	Gerenciar SQL Warehouses. Na Free Edition, já vem um Serverless Starter Warehouse criado.



Seção SQL (parte inferior do menu)


Menu	O que faz
SQL Editor	Editor de SQL com autocomplete. Executa queries diretamente no SQL Warehouse.
Queries	Suas queries SQL salvas e compartilhadas.
Dashboards	Dashboards interativos criados a partir de queries SQL.
Genie	Assistente de IA — faz perguntas em linguagem natural sobre seus dados.
Alerts	Alertas automáticos baseados em condições das suas queries.
SQL Warehouses	Mesma tela do Compute — visualiza e gerencia os warehouses.

Dica: Na Free Edition, o SQL Warehouse "Serverless Starter Warehouse" já vem criado e pronto. Ele liga automaticamente quando você executa uma query ou notebook, e desliga sozinho após alguns minutos de inatividade. Você não precisa fazer nada — só usar.



Parte 3 — Criando Seu Primeiro Notebook

Vamos criar um notebook, executar código Python e SQL, e confirmar que o ambiente está funcionando.




Passo a passo

Passo 1: No menu lateral esquerdo, clique em "+ New" (botão azul no topo).

Passo 2: Selecione "Notebook" no menu que aparece.

Passo 3: O notebook será criado automaticamente e conectado ao compute serverless. Você verá no topo do notebook a indicação de conexão (geralmente um ícone verde ou a palavra "Connected").




Dica: Diferente da Community Edition, aqui não é necessário selecionar ou criar um cluster. O compute é serverless e conecta automaticamente.

Passo 4: Na primeira célula, digite o código abaixo e pressione Shift+Enter (ou clique no botão de Play) para executar:


```
print("Hello Databricks MBA Engenharia de Dados!")
print(f"Spark version: {spark.version}")
print("Ambiente OK!")
```

Passo 5: Se as três mensagens aparecerem no output da célula, seu ambiente está 100% funcional.



Testando SQL

Na célula seguinte, vamos testar o modo SQL. Mude o tipo da célula para SQL (clcando no dropdown de linguagem no topo da célula) ou adicione o comando mágico %sql no início:



```
%sql
SELECT 'SQL funcionando!' AS status, current_timestamp() AS agora
```

Se aparecer uma tabela com uma linha mostrando o status e a data/hora, o SQL Warehouse está operacional.

Arquivo Editar Ver Executar Ajuda SQL ▾ Tabs: ATIVADO ▾ ☆ ▲ 🗪 ▶ Exe

▶ ▾ ✓ Agora mesmo (12s) 1

%sql
 SELECT 'SQL funcionando!' AS status, current_timestamp() AS agora
 > [Ver desempenho \(1\)](#)

Tabela ▾ +

	status	agora
1	SQL funcionand...	2026-03-05T18:17:25.927+00:00

Importando um notebook existente

Nos próximos labs, vocês receberão notebooks prontos no formato .py (Databricks notebook format). Para importar:

Passo 1: No menu lateral, clique em "Workspace".

Passo 2: Navegue até a sua pasta de usuário crie uma pasta chamada Labs

rafael.pereira01@cps.sp.gov.br

- > Draft
- > Labs
- > Group
- ★ Favorites
- 🗑️ Trash

Open in new browser tab
 View details
 Copy URL/path


+ Create

- Import
- Download as
- Share (Permissions)
- Add to favorites


Folder
 Git folder
 Notebook
 File
 Query
 Dashboard
 Genie space
 Visual data prep
 Markdown
 ETL Pipeline
 Legacy Alert
 Alert
 MLflow experiment

Lab01_Pipe


Passo 3: Clique com botão direito e selecione "Import".



Passo 4: Arraste o arquivo .py ou clique para seleccionar o arquivo no seu computador.



Passo 5: O notebook aparecerá na sua pasta, pronto para abrir e executar.



Parte 4 — Upload do Dataset card_transdata.csv


Para os laboratórios, vamos usar um dataset real de detecção de fraude em cartão de crédito do Kaggle.

Download do Kaggle

Passo 1: Acesse o dataset no Kaggle:

<https://www.kaggle.com/datasets/dhanushnarayanar/credit-card-fraud>

Passo 2: Clique no botão "Download" (será necessário criar conta gratuita no Kaggle, caso não tenha). O arquivo baixado será um .zip.




Passo 3: Descompacte o .zip para obter o card_transdata.csv.

Dica: O arquivo tem aproximadamente 1 milhão de registros e ~60 MB.


Upload para o Databricks

Passo 1: No menu lateral do Databricks, clique em "+ New".

Passo 2: Selecione a opção "File" (ou "Add or upload data" se aparecer essa opção).



Caminho alternativo: No menu lateral, clique em "Catalog". Depois clique no botão "Create Table" | "Adicionar Dados" no canto superior direito. Arraste o arquivo CSV para a área de upload.



Passo 3: Arraste o card_transdata.csv para a área indicada e aguarde o upload completar.

Passo 3.1: Criar um volume **aulamba**

Upload files to a Volume in Unity Catalog

Files
Upload any file format up to 5GB to Unity Catalog for analytics, AI and file-centric workflows such as ML on unstructured data, staging raw data before processing, or storing libraries and configuration files.

Create a new volume
Volumes are locations for storing files in Unity Catalog.

Volume name*
aulamba

Volume type [Learn more](#)
☒ **Managed volume**
Files are stored in a location managed by Unity Catalog.
☐ **External volume**
Files are stored in an external location that you configure.

Choose catalog and schema*
Volumes are organized under a catalog and a schema. Select existing or create new.

workspace default

Cancel Create

Volumes/Catalog/Schema/ No volume selected

Cancel Upload

Passo 4: O Databricks vai mostrar uma pré-visualização dos dados. Confirme que as colunas foram detectadas corretamente e clique em "Create Table" (ou equivalente).

Adicionar dados >

Criar ou modificar tabela a partir de upload de arquivo

card_transdata.csv carregado 76.28MB

Criar nova tabela

Modo de visualização: workspace

Catálogo: workspace

Esquema: default

Nome da tabela: card_transdata

Atributos avançados

Aguardando o início de Serverless Starter Warehouse

.00	distance_from_hor	.00	distance_from_last	.00	ratio_to_median_p	.00	repeat_retailer	.00	used_chip	.00
57.87785658389723		0.3111400080477545		1.9459399775518593		1.0		1.0		0.0
10.829942699255545		0.17559150228166587		1.2942188106198573		1.0		0.0		0.0
5.091079490616996		0.8051525945853258		0.42771456119427587		1.0		0.0		0.0
2.2475643282963613		5.60004354707232		0.36266257805709584		1.0		1.0		0.0
44.19093600261837		0.5664862680583477		2.2227672978404707		1.0		1.0		0.0

Cancelar Criar tabela

) Sua tabela "card_transdata" está sendo criada...

Dica: Na Free Edition com Unity Catalog, a tabela será criada no catálogo padrão. O caminho típico será algo como: workspace.default.card_transdata

Verificando o upload

Abra um notebook e execute:

```
df = spark.table('card_transdata')
print(f'Registros: {df.count():,}')
print(f'Colunas: {len(df.columns)}')
df.printSchema()
display(df.limit(10))
```

1
SQL
🗑️
✳️
🔍
⋮

❗ Falha na última execução

```

1 df = spark.table('card_transdata')
2 print(f'Registros: {df.count():,}')
3 print(f'Colunas: {len(df.columns)}')
4 df.printSchema()
5 display(df.limit(10))
6
> Ver desempenho \(1\)

```

[PARSE_SYNTAX_ERROR] Syntax error at or near 'df'. SQLSTATE: 42601

✳️ Erro de diagnóstico Correção rápida do Assistente: ATIVADO

Hahahaha, trocar para Python

Arquivo
Editar
Ver
Executar
Ajuda
Python
Tabs: ATIVADO
☆

Interromper
00:09
1

```

1 df = spark.table('card_transdata')
2 print(f'Registros: {df.count():,}')
3 print(f'Colunas: {len(df.columns)}')
4 df.printSchema()
5 display(df.limit(10))
> Ver desempenho Comandos 1/2 | Tarefas

```

Registros: 1,000,000
Colunas: 8

```

root
|-- distance_from_home: double (nullable = true)
|-- distance_from_last_transaction: double (nullable = true)
|-- ratio_to_median_purchase_price: double (nullable = true)
|-- repeat_retailer: double (nullable = true)
|-- used_chip: double (nullable = true)
|-- used_pin_number: double (nullable = true)
|-- online_order: double (nullable = true)
|-- fraud: double (nullable = true)

```

Se o upload foi feito como arquivo (sem criar tabela), use o caminho DBFS:

```
df = spark.read.csv('/FileStore/tables/card_transdata.csv', header=True, inferSchema=True)
```

```
df = spark.read.csv(
    "/Volumes/workspace/default/aulamba/card_transdata.csv",
    header=True,
    inferSchema=True
)
```

```
print(f"Registros: {df.count():,}")
print(f"Colunas: {df.columns}")
df.printSchema()
display(df.limit(10))
```

Sobre o dataset

O card_transdata.csv contém aproximadamente 1 milhão de transações de cartão de crédito com as seguintes colunas:

Coluna	Descrição
distance_from_home	Distância da transação em relação à residência do titular
distance_from_last_transaction	Distância em relação à última transação realizada
ratio_to_median_purchase_price	Razão entre o valor da compra e a mediana de compras do titular
repeat_retailer	Varejista já utilizado antes (0 = não, 1 = sim)
used_chip	Chip do cartão utilizado (0 = não, 1 = sim)
used_pin_number	Senha PIN utilizada (0 = não, 1 = sim)
online_order	Compra feita online (0 = não, 1 = sim)
fraud	Transação fraudulenta (0 = legítima, 1 = fraude). Campo-alvo.

Dica: Este dataset será utilizado no Lab 01 (pipeline de detecção de fraude).

```
> df: pyspark.sql.connect.dataframe.DataFrame = [distance_from_home: double, distance_from_last_transaction: double ... mais 6 campos]
Registros: 1,000,000
Colunas: 8
root
 |-- distance_from_home: double (nullable = true)
 |-- distance_from_last_transaction: double (nullable = true)
 |-- ratio_to_median_purchase_price: double (nullable = true)
 |-- repeat_retailer: double (nullable = true)
 |-- used_chip: double (nullable = true)
 |-- used_pin_number: double (nullable = true)
 |-- online_order: double (nullable = true)
 |-- fraud: double (nullable = true)
```

Troubleshooting — Problemas Comuns

"Não consigo fazer login com meu e-mail FIAP"

Verifique se está usando o e-mail correto no formato @fiap.com.br. Se o login Microsoft não funcionar, tente limpar cookies do navegador ou usar uma janela anônima. Se persistir, entre em contato com o professor.

"O notebook está 'Connecting...' e não avança"

O compute serverless pode levar de 30 segundos a 2 minutos para inicializar na primeira execução. Aguarde. Se ultrapassar 3 minutos, tente recarregar a página (F5).

"Erro 'Table not found' ao tentar ler o dataset"

O nome da tabela pode variar dependendo de como o upload foi feito. Use o Catalog (menu lateral) para encontrar o nome exato da tabela. Clique na tabela e copie o nome completo (geralmente no formato catalogo.schema.nome_tabela).

"O upload do arquivo trava ou dá erro"

Tente usar Chrome ou Edge atualizado. Se o arquivo for muito grande, uma alternativa é usar apenas as primeiras 100.000 linhas para testar. Outra opção é fazer o upload via notebook usando o botão File → Upload Data.

"O SQL Warehouse aparece como 'Stopped'"

Ele liga automaticamente quando você executa uma query. Clique em qualquer query SQL ou execute uma célula no notebook — o warehouse vai iniciar sozinho. Se não iniciar em 2 minutos, tente clicar no nome do warehouse e depois no botão "Start".

"Apareceu 'Resource quota exceeded'"

A Free Edition tem limites de uso simultâneo. Se muitos alunos estiverem rodando queries pesadas ao mesmo tempo, pode acontecer. Aguarde 1-2 minutos e tente novamente. Em último caso, feche outros notebooks abertos.

Próximo passo

Com o ambiente configurado e o dataset carregado, você está pronto para o Lab 01, onde vamos construir um pipeline completo de detecção de fraude usando a arquitetura Bronze → Silver → Gold com Delta Lake.

Professor: Rafael S Novo Pereira

Disciplina: Data Integration e Pipelines — FIAP MBA Data Engineering

Referências

Databricks Free Edition — Documentação oficial:

<https://docs.databricks.com/aws/en/getting-started/free-edition>

Limitações da Free Edition:

<https://docs.databricks.com/aws/en/getting-started/free-edition-limitations>

Dataset card_transdata — Kaggle:

<https://www.kaggle.com/datasets/dhanushnarayanar/credit-card-fraud>